

Dados como produto e contexto autorizado

Pílula de Principal Engineering – fonte de verdade, qualidade, linhagem, freshness e autorização no caminho do RAG

O QUE ESTA PÍLULA TREINA

Explicar por que RAG não é apenas indexar documentos: é construir um caminho de dados confiável, atualizado, rastreável e autorizado para cada usuário e decisão.

1. A frase-mestra

Contexto útil é contexto permitido, atual e comprovável. Se o sistema recupera um documento errado, vencido ou fora da autorização do usuário, uma resposta fluente apenas torna o erro mais perigoso.


Resposta de Principal: "Eu trataria dados para IA como produto: com owner, contrato, classificação, qualidade, linhagem, freshness, autorização e SLO. O retriever só pode entregar ao modelo o subconjunto que o usuário está autorizado a conhecer."

2. FONTE: cinco letras para recuperar o desenho

F Freshness Qual a vigência? O dado mudou? Como detectar atraso e invalidar índice?	O Ownership Quem é dono do domínio, do contrato, da qualidade e da autorização?	N Não confiar cegamente Qualidade, completude, duplicidade, conflito e fonte de verdade.	T Traceability Qual documento, versão, chunk e transformação sustentam a resposta?	E Entitlement Quem pode acessar? A política é aplicada antes do contexto chegar ao modelo?
---	---	--	--	--

Regra de retenção: quando perguntarem sobre RAG, responda FONTE antes de falar em embeddings ou banco vetorial.

3. O pipeline que um Principal desenha



ETAPA	DECISÃO DE ENGENHARIA	FALHA MATADORA
Fonte	usar sistema de registro, evento, documento ou dado derivado?	copiar uma base sem dono e sem política de atualização
Contrato	definir schema, semântica, vigência, owner, classificação e SLA	chunk sem contexto de produto, região ou data
Classificação	marcar sensibilidade, tenant, domínio, finalidade e grupos autorizados	tentar corrigir autorização só no prompt
Indexação	preservar metadados, versão do documento, hash e referência à origem	embedding sem como voltar ao documento original
Retrieval	derivar filtros da identidade e da política do usuário antes da busca	buscar tudo e pedir ao modelo para "não revelar"
Resposta	citar fontes, indicar vigência, abster-se quando evidência for insuficiente	responder com confiança sem proveniência

Armadilha: filtro de metadado é tratado como autorização completa. **Upgrade:** "O filtro reduz o conjunto candidato, mas a autorização precisa ser derivada de identidade e política; o sistema de origem continua sendo a referência para acesso e o log precisa registrar a decisão."

4. O contrato de um dado pronto para IA

Semântica

- o que o campo significa
- unidade, domínio e regra de cálculo
- exemplo válido e exemplo inválido

Freshness

- data de atualização e vigência
- SLA de ingestão e atraso aceitável
- evento de invalidação ou reprocessamento

Qualidade

- completude, unicidade e consistência
- regras de reconciliação com a fonte
- quarentena para conteúdo suspeito

Privacidade

- classificação e finalidade de uso
- minimização e retenção
- redação antes de indexar ou logar

Autorização

- tenant, papel, atributo ou relação do usuário
- política que decide leitura e ação
- revogação e deleção testadas

Proveniência

- origem, versão, hash e transformação
- referência do chunk ao documento
- evidência citável na resposta

5. Dados em movimento: batch, CDC ou consulta em tempo real?

ESTRATÉGIA	QUANDO FAZ SENTIDO	TRADE-OFF
Batch	políticas, manuais, documentos com mudança previsível	mais simples e barato; risco de ficar vencido entre cargas
CDC ou eventos	mudanças de apólice, status de sinistro e permissões	freshness melhor; exige ordenação, idempotência e replay

ESTRATÉGIA	QUANDO FAZ SENTIDO	TRADE-OFF
Consulta na fonte	saldo, limite, status ou dado altamente sensível e mutável	mais atual e autorizado; adiciona latência, quota e dependência
Híbrido	documentos no índice e fatos críticos em tool síncrona	melhor equilíbrio; exige contrato claro sobre o que é memória e o que é fonte

Heurística: "Se o fato muda rápido, tem alto impacto ou é pessoal, prefiro buscar na fonte. Se é conhecimento estável e compartilhado, uso índice com vigência e proveniência. O agente nunca deve inventar um compromisso de consistência que o pipeline não garante."

6. Caso de entrevista: assistente de seguros para corretor

CASO DE BANCO E SEGUROS

DADOS SENSÍVEIS

CONTEXTO AUTORIZADO

"Desenhe um assistente que responda dúvidas do corretor sobre coberturas e apólices."

Fonte: manuais e condições gerais entram em RAG; status, vigência, cobertura contratada e dados do cliente vêm de tools autorizadas. Não misturo fato de apólice com memória semântica.

Contrato: cada documento tem produto, versão, região, vigência, finalidade, classificação, owner e hash. Cada chunk aponta para o documento original e para a página ou seção citável.

Entitlement: o token do corretor e seu vínculo com a carteira produzem filtros de tenant, produto e cliente. A busca já nasce restrita; a tool valida novamente antes de devolver dado individual.

Freshness: publicação ou alteração de condição geral gera evento de ingestão; cancelamento, endosso ou revogação invalida cache e força consulta à fonte. Métricas acompanham atraso de indexação, documentos sem owner e respostas sem citação.

Abstenção: se a apólice não é encontrada, a vigência é ambígua ou há conflito entre fontes, o assistente não estima cobertura. Ele apresenta a lacuna, cita o que sabe e encaminha para o fluxo humano.

Frase forte: "Eu não prometeria que o LLM conhece a apólice. Eu projetaria uma resposta baseada em duas camadas: conhecimento documental versionado e fatos contratuais consultados em tempo real, ambos com autorização e citação."

7. O que observar no plano de dados

Qualidade e freshness

completude, duplicidade, conflitos, atraso de ingestão, documentos vencidos, taxa de falha no parser e cobertura do corpus.

Retrieval

recall de evidência, precisão dos chunks, taxa de consulta sem resultado, filtros aplicados, tempo de busca e citações válidas.

Privacidade

violações de política, tentativas bloqueadas, acesso cross-tenant, PII em logs, retenção, deleção e revogação propagada.

Outcome

tempo de resposta, resolução no primeiro contato, override humano, escalonamentos, retrabalho e incidentes por domínio.

8. Perguntas de entrevista e respostas curtas

"Por que não colocar tudo no vetor?"

Porque nem todo dado é conhecimento estável. Fatos críticos, mutáveis ou altamente sensíveis devem ser consultados na fonte autorizada, com contrato e timeout.

"Como impedir vazamento entre clientes?"

Identidade e política viram filtros antes do retrieval; a tool aplica autorização na fonte; o runtime registra decisão e tenta de acesso. Prompt não é controle de acesso.

"Como tratar documento vencido?"

Metadados de vigência, evento de invalidação, filtro temporal, alerta de atraso e teste que consulta a versão esperada. Sem vigência confiável, abstenção.

"Qual o papel do data owner?"

Definir semântica, finalidade, qualidade, retenção, autorização e condição de mudança. Engenharia não deve inferir sozinha o significado operacional de um dado.

"Como escolher entre RAG e fine-tuning?"

RAG é melhor quando preciso de fatos atuais, citação e controle de acesso por documento. Fine-tuning muda comportamento ou estilo, mas não substitui fonte de verdade nem revogação.

"Como você mede qualidade do RAG?"

Separaria retrieval e geração: evidência encontrada, relevância, cobertura, citação, groundedness, abstention, latência, custo e outcome por segmento.

9. Resposta de 60 segundos

"Eu começaria pelo **FONTE: freshness, ownership, não confiar cegamente, traceability e entitlement**. Classificaria o caso em conhecimento documental ou fato transacional. O primeiro iria para uma pipeline com contrato, metadata de vigência e proveniência; o segundo seria consultado na fonte por tool autorizada. No retrieval, identidade e política do usuário gerariam filtros antes da busca, e a autorização seria reforçada na origem. Eu monitoraria qualidade, atraso, acesso indevido, citações e outcome. Se a fonte estiver vencida, houver conflito ou a autorização não puder ser comprovada, a resposta correta é abster-se e encaminhar. O modelo recebe apenas contexto permitido e comprovável."

10. Exercício de 15 a 20 minutos

- [] Escreva FONTE de memória e dê um exemplo de falha para cada letra.
- [] Escolha um caso seu e separe dez dados entre "indexar" e "consultar na fonte".
- [] Desenhe os metadados mínimos de um chunk: origem, versão, vigência, tenant, classificação, finalidade e owner.
- [] Defina dois alertas de freshness, dois de qualidade e dois de autorização.
- [] Responda em voz alta: "Por que um prompt dizendo para não revelar dados não é suficiente?"

Teste final: se você não consegue apontar a fonte de verdade, a política de acesso e a condição de abstenção, ainda não há contexto pronto para produção.

11. Referências oficiais

Esta pílula combina princípios de privacidade, governança de dados e orientação técnica de retrieval seguro. As referências abaixo são oficiais e servem como base para aprofundamento.

- [NIST Privacy Framework](#) - gestão de risco de privacidade e governança de dados.
- [AWS Prescriptive Guidance - secure access to data and systems for generative AI](#) - classificação, filtros de metadata, proteção e acesso em RAG.
- [Amazon Bedrock RetrievalFilter](#) - filtros aplicados aos metadados antes do retorno das fontes.
- [AWS Prescriptive Guidance - Knowledge Bases for Amazon Bedrock](#) - ingestão incremental, metadata e atualização de bases.

Como usar: 15 minutos de leitura, 5 minutos de recuperação sem consulta, 2 minutos de resposta falada.

Frase para levar: contexto útil é contexto permitido, atual e comprovável.